



河南大學
Henan University

《自然语言处理》 实验指导

河南大学计算机与信息工程学院

二〇二四年九月

说明

1、飞桨AI Studio星河社区课程主页

<https://aistudio.baidu.com/education/group/info/29029>

在该课程主页利用对应的平台完成实验。

2、实验既可以通过Pytorch框架完成，也可以基于PaddlePaddle完成。

3、实验最后要提交代码和实验报告文档。请使用A4版式的电子实验报告。要求所有实验必须提交实验源代码和实验报告。二者的命名方式为“学号-姓名-自然语言处理-实验X.rar”，其中#代表具体的实验编号。实验代码和实验报告分开提交。例如，如果是实验1，则#替换为1，以此类推。

实验一中文分词

一、实验目的

- 1、熟悉并掌握百度AI Studio实践平台的账户创建与实践基本操作。
- 2、理解并掌握基于词表的三种分词算法：正向最大匹配算法FMM，逆向最大匹配算法RMM和双向最大匹配算法BM。

二、实验内容

分词就是将连续的字序列按照一定的规范重新组合成语义独立词序列的过程。中文分词是文本挖掘的基础，对于输入的一段中文，成功的进行中文分词，可以达到电脑自动识别语句含义的效果。中文分词技术属于自然语言处理技术范畴，对于一句话，人可以通过自己的知识来明白哪些是词，哪些不是词，但如何让计算机也能理解？其处理过程就是分词算法。基于词表的分词算法也称为基于规则的分词算法。

本实验我们分别利用三种基于词表的分词算法对一段话进行分词。

三、实验语言和平台

Python3.7, AI Studio 平台, 本实验需要4学时。

四、实验内容和分析

进入课节4，查看实验内容《基于词表的三种分词算法》，读懂程序，为主要代码做注释。并对实验中的代码进行如下改进，并在实验报告中给出关键代码。

- 1、教材中的词典是一个List数组，此表比较小，不符合实际情况，请编写函数 `load_dict(file_path)` 加载结巴分词自带的词典 `dict.txt`，提取其中的词语构成词典，并求词典中最大单词的长度。
- 2、对FFM、RMM和BM程序进行改造，能够传入构造的词典和最大词的长度。
- 3、运行程序，能够在控制台显示输入“请输入需要分词的段落：”，然后输入一个需要分词的段落。
- 4、显示分词结果并输出。

实验二 关键词提取

一、实验目的

理解并掌握TextRank关键字提取算法。

三、实验内容

TextRank算法是一种基于图的用于关键词抽取和文档摘要的排序算法，由谷歌的网页重要性排序算法PageRank算法改进而来，它利用一篇文档内部的词语间的共现信息(语义)便可以抽取关键词，它能够从一个给定的文本中抽取出该文本的关键词、关键词组，并使用抽取式的自动文摘方法抽取出该文本的关键句。TextRank算法的基本思想是将文档看作一个词的网络，该网络中的链接表示词与词之间的语义关系。

本实验我们分别利用结巴工具和TextRank4zh两种方法实现TextRank算法。

三、实验语言和平台

Python3.7，AI Studio 平台，本实验需要4学时。

四、实验内容和分析

(1) 进入课节5，查看实验内容《基于TextRank算法的两种关键词提取》，读懂这两种算法，为主要代码做注释，自行编写代码完成，输出“燕山大学是河北省人民政府、教育部、工业和信息化部、国家国防科技工业局四方共建的全国重点大学，河北省重点支持的国家一流大学 and 世界一流学科建设高校，北京高科大学联盟成员。”这段话的关键词和权重。

(2) 从河南大学新闻网上自行寻找一篇新闻，将其粘贴在一个记事本文件中，然后在代码中读取这个文件，分别使用jieba工具和TextRank4zh提供的抽取关键词的方法来输出关键词，可以尝试输出5个、10个等。

(3) 编写一个停用词过滤算法，其能够读取停用词表，并且对读入的文档进行停用词过滤后再利用TextRank4zh进行关键词抽取，尝试设置TextRank4Keyword对象的analyze的window参数大小，查看输出的关键词有何区别。

(4) 请给出jieba工具和TextRank4zh两种获取的关键词的方法的差异。

实验三 词向量技术

一、实验目的

理解并掌握Skip-gram词向量模型的训练以及词的余弦相似度计算。

二、实验内容

使用飞桨实现Skip-gram模型的方法，对PyTorch或者TensorFlow框架熟悉的同学也可以将程序改造为对应机器学习框架的算法。如果电脑上具有GPU，请尝试将程序放到GPU上去运行。

在飞桨中，不同深度学习模型的训练过程基本一致，流程如下：

- 1、**数据处理**：选择需要使用的数据，并做好必要的预处理工作。
- 2、**网络定义**：使用飞桨定义好网络结构，包括输入层，中间层，输出层，损失函数和优化算法。
- 3、**网络训练**：将准备好的数据送入神经网络进行学习，并观察学习的过程是否正常，如损失函数值是否在降低，也可以打印一些中间步骤的结果出来等。
- 4、**网络评估**：使用测试集合测试训练好的神经网络，看看训练效果如何。

实验中运行可能的结果输出如下：

单词 1 king 和单词 2 queen 的 cos 结果为 0.879609

单词 1 she 和单词 2 her 的 cos 结果为 0.933683

单词 1 topic 和单词 2 theme 的 cos 结果为 0.933814

单词 1 woman 和单词 2 game 的 cos 结果为 0.647447

单词 1 one 和单词 2 name 的 cos 结果为 0.504287

三、实验语言和平台

Python3.7，AI Studio平台。本实验需要4学时。

四、实验内容和分析

进入课节6，查看实验内容《实验三 词向量技术》，完成实验项目《Skip-gram词向量模型的训练以及词的余弦相似度计算》，读懂模型算法，完全理解算法的基本原理，为主要代码做注释（不局限于平台已经提供的注释），分析输出结果，并回答如下问题：

- （1）谈谈你对程序的SkipGram类中self.embedding作用的理解。
- （2）build_data()方法的作用是什么，输出数据的构成是怎样的？

实验四 文本分类

一、实验目的

理解并掌握基于朴素贝叶斯的文本分类方法。

三、 实验内容

在飞桨中，基于朴素贝叶斯的文本分类是一种十分简单的分类算法，其算法原理进行文本分类的思路很容易理解：对于给出的待分类文本，抽取它的文本特征（例如主题词），然后求解该特征出现条件下属于各个类别的概率，哪个最大，就认为待分类文本属于那个类别。

本实验我们使用基于朴素贝叶斯的文本分类方法对垃圾邮件进行分类。

三、实验语言和平台

Python3.7，AI Studio 平台，本实验需要4学时。

四、实验内容和分析

进入课节7，查看实验内容《使用朴素贝叶斯分类算法实现垃圾邮件分类》，请读懂本程序代码，写出各部分代码完成的具体工作，并对数据集（已引入项目文件夹）中151到155号邮件进行预测，是垃圾邮件还是普通邮件，并输出结果。

实验五 命题实体识别


一、实验目的

理解并掌握基于LSTM（long-short term memory）的命名空间识别算法。

二、实验内容

目前命名实体识别领域比较流行的方法都是把命名实体识别问题转换为一个序列标注的问题，然后通过序列标注的方法来解决。一般序列标注的解决方法有：隐马尔科夫模型HMM或 条件随机场 CRF 或BiLSTM+CRF 或BiLSTM+最大熵。其中前两种是统计学习方法，后面两种是神经网络的方法。

本次实验我们要学习的BiLSTM-CRF 模型是命名实体识别的一个经典的解决方法，是基于神经网络的方法。它由双向的 LSTM 网络后叠加一个 CRF（条件随机场）层组成，其结构如图所示：



三、实验语言 and 平台

Python3.7，AI Studio 平台，本实验需要4学时。

四、实验内容和分析

进入课节8，查看实验内容《实验五命名实体识别》，完成项目《基于LSTM的命名实体识别》，读懂算法，为主要代码做注释，对算法进行验证。

实验六 实体关系抽取

一、实验目的

理解并掌握基于预训练的实体关系抽取方法。

二、实验内容

关系抽取是文本信息抽取的另一个子任务，关系抽取以实体识别为前提，在实体识别之后，判断给定文本中的任意两个实体是否构成事先定义好的关系，是文本内容理解的重要支撑技术之一，对于问答系统，智能客服和语义搜索等应用都十分重要。

本项目基于预训练的实体关系抽取，为关系抽取任务提出预训练模型，然后再针对不同数据集预训练模型，对关系抽效果有较大提升。

三、实验语言和平台

Python3.7，AI Studio 平台，本实验需要4学时。

四、实验内容和分析

进入课节8，查看实验内容《实验六 实体关系抽取》，完成项目《基于预训练模型的实体关系抽取》，读懂算法，为主要代码做注释，对算法进行验证

实验七 机器阅读理解


一、实验目的

理解并掌握基于预训练模型的抽取式阅读理解。

二、实验内容

机器阅读理解（Machine reading comprehension, MRC）是让机器具有阅读理解并理解文章的能力。也是自然语言处理的核心任务之一。本次实验将练习机器阅读理解中抽取文章片段作为答案的任务——抽取式阅读理解中的基于预训练模型的抽取式阅读理解算法。得益于预训练模型包含的海量的参数，它可以有效地从大量的未标注文本中学习到知识。

基于预训练模型的抽取式阅读理解模型（SpanQA）包含表征层和输出层，其中表征层负责对输入进行交互与表征，而输出层负责对答案片段进行预测，整体架构如下图所示。



三、实验语言和平台

Python3.7, AI Studio 平台, 本实验需要4学时。

四、实验内容和分析

进入课节9，查看实验内容《实验七 机器阅读理解实验书》，完成实验项目《基于预训练模型的抽取式阅读理解》，读懂模型算法，为主要代码做注释，并对算法进行验证。

实验八 文本生成与文本摘要

一、实验目的

理解并掌握基于预训练模型的生成式文本摘要。

二、实验内容

一个好标题则是基于文章内容的巧妙提炼，能迅速引起读者的兴趣。为了快速精准的生成新闻标题，本项目使用经典的 BERT 模型自动完成新闻标题的生成。

BERT (**B**idirectional **E**ncoder **R**epresentations from **T**ransformers) 意为来自 Transformer 的双向编码器表征。不同于最近的语言表征模型，BERT 旨在基于所有层的左、右语境来预训练深度双向表征。因此，预训练的 BERT 表征可以仅用一个额外的输出层进行微调，进而为很多任务(如问答和语言推理)创建当前最优模型，无需对任务特定架构做出大量修改。




Figure 1: Overall pre-training and fine-tuning procedures for BERT. Apart from output layers, the same architectures are used in both pre-training and fine-tuning. The same pre-trained model parameters are used to initialize models for different down-stream tasks. During fine-tuning, all parameters are fine-tuned. [CLS] is a special symbol added in front of every input example, and [SEP] is a special separator token (e.g. separating questions/answers).

三、实验语言和平台

Python3.7, AI Studio 平台，本实验需要4学时。

四、实验内容和分析

进入课节10，查看实验内容《实验八 文本生成与文本摘要》，完成实验项目《基于BERT的文本标题生成》，读懂模型算法，为主要代码做注释，并对算法进行验证。